Краткая оценка голосового ввода и OCR

Локальный сервер и API для CRM в Украине

Итог. Для целевой задержки до 5 секунд предпочтительна потоковая транскрипция gpt-live-transcribe. При 500 минутах голоса и 1 000 OCR изображений полная платная стоимость API составляет около 448 грн ($10) в месяц без бесплатных квот, либо 537 грн ($12) с бюджетным резервом 20%. Рыночная медиана компонентов локального сервера составляет около 99 350 грн ($2 218).

Исходные параметры

Параметр	Принято в расчёте
Пользователи	До 20 одновременно
Пиковая AI нагрузка	До 2–3 одновременных операций
Месячный объём	500 минут голоса и 1 000 OCR изображений
Целевая задержка	До 5 секунд после окончания ввода; практическая цель p95
Курс	44,7863 грн за $1 на 23.09.2026
Горизонт	5 и 10 лет, без инфляции и изменения тарифов

Технологии и быстродействие

Функция	Локально	API и оценка
Голос	faster-whisper INT8 на RTX 3070 Ti	gpt-live-transcribe; Tier 1 до 500 RPM; p95 до 5 секунд реалистичен при передаче аудио во время записи
OCR	Tesseract; PaddleOCR при необходимости	Google Cloud Vision; 1 800 RPM; синхронный OCR обычной фотографии обычно укладывается в целевой бюджет

Ограничение текущей системы

Приложение допускает одну операцию Speech и одну операцию OCR одновременно. При 2–3 запросах одного типа последующие запросы получают HTTP 429. Для использования доступной мощности API потребуется очередь или ограничитель на три параллельные операции. Внешние API не дают абсолютной гарантии 5 секунд, поэтому показатель нужно подтвердить нагрузочным тестом.

Компонентная стоимость локального сервера

Для каждой позиции использован центральный рыночный ориентир по активным предложениям украинских магазинов и агрегаторов на 23.09.2026. Единичные минимальные цены не использовались; значения округлены до 50 грн. Для RTX 3070 Ti учитывался фактический рынок, где значительная часть предложений является восстановленной или бывшей в употреблении.

Компонент	Конфигурация	Медианный ориентир
CPU	Intel Core i7-12700F, 12 ядер / 20 потоков	14 700 грн / $328
GPU	GeForce RTX 3070 Ti 8 ГБ	21 200 грн / $473
Материнская плата	B760, DDR4, LGA1700	5 950 грн / $133
Оперативная память	64 ГБ DDR4-3200	31 500 грн / $703
Накопитель	NVMe SSD 2 ТБ	14 950 грн / $334
Блок питания	850 Вт, 80 Plus Gold	5 300 грн / $118
Охлаждение CPU	Башенный кулер LGA1700	1 800 грн / $40
Корпус	ATX с четырьмя вентиляторами	3 950 грн / $88
Итого	**Рыночная медиана компонентов**	**99 350 грн / $2 218**

Что включено и исключено

- Включены только восемь компонентов из таблицы; это ориентир украинской розницы, а не коммерческое предложение конкретного поставщика.
- Не включены сборка, ОС, лицензии, ИБП, резервное хранилище, электроэнергия, интернет, обслуживание, администрирование, ремонт и замена компонентов.
- Покупка новой RTX 3070 Ti с полноценной гарантией может стоить выше медианы из-за ограниченного количества нового товара.

Ресурсная достаточность

Ресурс	Оценка
GPU 8 ГБ	Достаточно для одного постоянного faster-whisper worker в INT8; не для трёх независимых крупных моделей
CPU 12 ядер	Достаточно для PHP, MySQL, декодирования аудио и 1–2 CPU OCR workers
RAM 64 ГБ	Даёт запас для БД, workers, кэша и фоновых задач
Пик 2–3 операции	Обслуживается через очередь; задержку p95 нужно подтвердить тестом

Стоимость API за месяц без бесплатных квот

Технология	Расчёт	Цена в месяц
gpt-live-transcribe	500 мин × $0,017	$8.50 / 381 грн
Google Vision OCR	1 000 изображений × $1,50 / 1 000	$1.50 / 67 грн
Полная платная стоимость	Бесплатная квота OCR не применяется	$10.00 / 448 грн
Плановый бюджет	**+20% резерв**	**$12.00 / 537 грн**

Резерв 20% предназначен для возможного НДС, банковской конвертации и небольших сопутствующих платежей. Он не является частью тарифа поставщиков. Расчёт OCR намеренно использует платную ставку, хотя Google предоставляет первые 1 000 единиц в месяц бесплатно.

Актуализированное сравнение на 5 и 10 лет

Вариант	5 лет	10 лет	Условие
Локальный сервер	99 350 грн / $2 218	99 350 грн / $2 218	Компоненты, одна закупка
API	32 246 грн / $720	64 492 грн / $1 440	Полные тарифы и резерв 20%
Разница	Сервер дороже в 3.1 раза	Сервер дороже в 1.5 раза	Без замены сервера

Преимущества и недостатки

Вариант	Преимущества	Недостатки
Локальный сервер	Данные остаются локально; фиксированная мощность; офлайн работа	99 350 грн сразу; один GPU является точкой отказа; 8 ГБ VRAM ограничивают рост
API	Низкий стартовый бюджет; масштабирование; мощности достаточно для 2–3 одновременных запросов	Нет жёсткой гарантии 5 секунд; зависимость от сети, квот и будущих тарифов

Вывод

При заданном объёме рекомендуется API. Полная платная стоимость составляет около 448 грн ($10) в месяц и 537 грн ($12) с резервом. За 5 лет API потребует около 32 246 грн ($720), за 10 лет - 64 492 грн ($1 440). Медианная стоимость компонентов сервера составляет 99 350 грн ($2 218), поэтому даже без электроэнергии и обслуживания условная точка равенства наступает примерно через 15 лет. Локальный сервер оправдан требованиями конфиденциальности, офлайн режимом или дополнительными AI задачами.

Источники и методика

OpenAI Docs: gpt-live-transcribe - $0,017 за минуту и Tier 1 до 500 RPM: https://developers.openai.com/api/docs/models/gpt-live-transcribe
Google Cloud Vision: платная ставка Text Detection $1,50 за 1 000 единиц: https://cloud.google.com/vision/pricing
Курс USD/UAH на 23.09.2026: 44,7863 грн за $1; источник данных НБУ: https://bank.gov.ua/ua/markets/exchangerate-chart
Рыночные цены компонентов: Hotline, Rozetka и Telemart, активные предложения на 23.09.2026. Для каждой категории использован центральный ценовой ориентир, округлённый до 50 грн.